Inteligencia de Talento: AI Systems & Agent Infrastructure (2026–2027)

Guía Ejecutiva de Mercado B2B desde Chile/LatAm ($4,000 – $10,000+ USD/mes), Pruebas Técnicas y Conversión con Runtime Propio

1. Los Cinco Títulos que Concentran el Presupuesto B2B en 2026–2027

El mercado de contratación remota desde Chile y Latinoamérica hacia Estados Unidos en 2026 dejó atrás los perfiles enfocados en encadenar prompts o levantar chatbots básicos con LangChain. Hoy, el presupuesto de ingeniería para contratos B2B de **$4,000 a $10,000+ USD/mes ($48,000 a $120,000+ USD/año)** se concentra en resolver cuellos de botella de sistemas distribuidos: ejecución determinista de agentes con estado, aislamiento seguro de código no confiable, protocolos estandarizados de herramientas (Model Context Protocol) y puertas de evaluación continua en CI/CD. Mientras en Estados Unidos el salario base para estos perfiles supera los $185,000–$240,000 USD anuales (South 2026 Benchmarks), las compañías estadounidenses captan ingenieros Senior en husos horarios compatibles (CLT/ART/BRT) reduciendo costos directos sin sacrificar arquitectura.

Título Exacto (2026)	Responsabilidad Real en Producción	Rango B2B Mensual	Ofertas y Portales Verificados
Forward Deployed AI Engineer (FDE)	Despliegue de agentes autónomos sobre infraestructura de clientes corporativos (banca, pagos, salud), integración con APIs heredadas, control de alucinaciones y diseño de guardrails deterministas en campo.	$6,560 – $12,190+ USD	Artefact US (OpenAI), Runtime (YC), Retell AI (YC), Toku, Silver.dev
Agentic Infrastructure / Runtime Engineer	Construcción de máquinas de estado (FSM), motores de ejecución duradera (Temporal, Inngest), sandboxes efímeros (Firecracker/gVisor) y recuperación de fallos multi-agente.	$6,000 – $11,500+ USD	Output Labs (YC), BairesDev Agentic, E2B, Vambe AI
Context / MCP Platform Engineer	Diseño de servidores y pasarelas MCP (Streamable HTTP), descubrimiento dinámico de herramientas, control de permisos OAuth 2.1 y mitigación de *Tool Poisoning*.	$5,500 – $10,500+ USD	Qase (MCP & DevTools), Contractor Gorilla, Niuro
AI Evaluation & Reliability Engineer	Arquitectura de *eval harnesses* en CI/CD, entornos contenerizados de verificación RL, métricas de consistencia (Pass^k), telemetría OpenTelemetry y colas HITL.	$5,200 – $10,000+ USD	Niuro (Governance), Revelo Frontier Evals, OpenTrain AI, Braintrust

Título Exacto (2026)	Responsabilidad Real en Producción	Rango B2B Mensual	Ofertas y Portales Verificados
Inference Optimization & AI Systems Engineer	Reducción de TTFT (Time-To-First-Token), enrutamiento semántico de modelos, cuantización, caché de prefijos y motores de búsqueda vectorial/híbrida de baja latencia.	$4,500 – $9,580+ USD	Improving, Zaelot, Kueski (Staff AI), Nubank

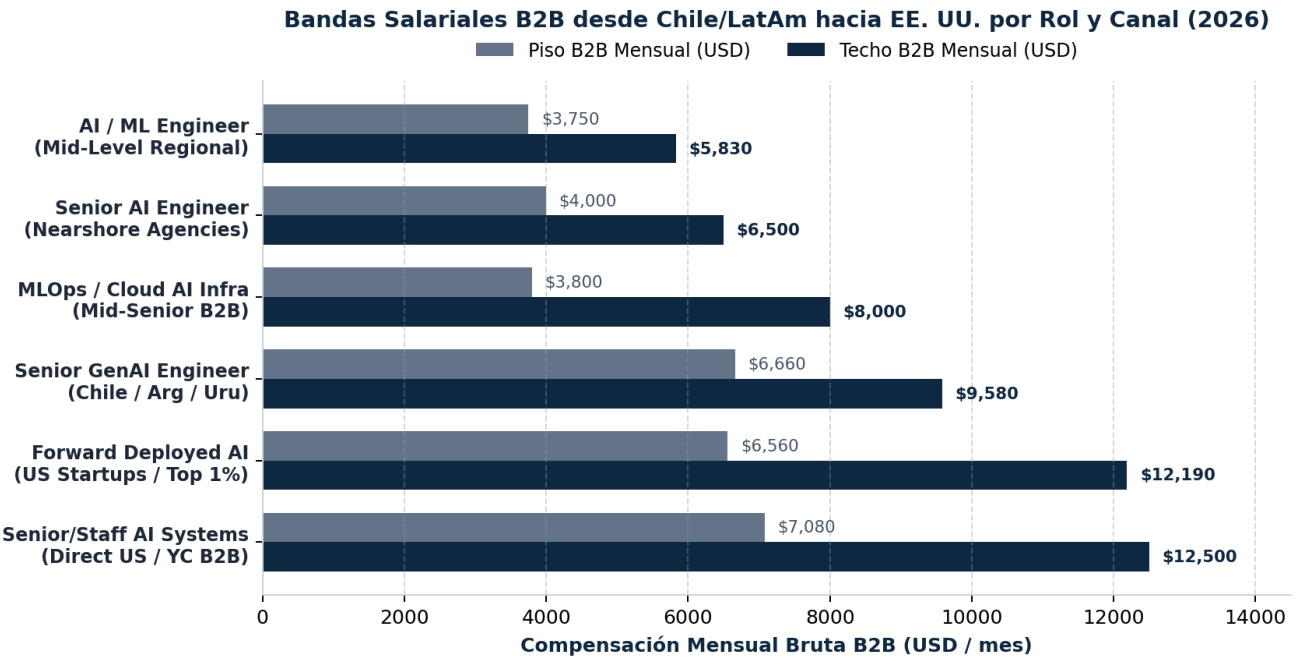


Figura 1: Comparativa de pisos y techos salariales mensuales B2B en USD desde Chile/LatAm según rol y canal de contratación (Fuentes: South 2026, Revelo, AY Automate, Get on Board).

Radiografía de Plataformas y Empresas Contratando Activamente desde Chile/LatAm

- **Get on Board (Chile y Sudamérica Remoto):** Destacan vacantes B2B en USD para Senior Forward Deployed AI Engineer (OpenAI) en Artefact US y Senior Deployed AI Engineer (Anthropic) en Artefact US, además de Niuro ($4,000–$5,000 USD/mes para Senior AI Engineer — LLMs/RAG/Agents), Zaelot, Improving (Qwen & GenAI) y VARTEQ Inc.
- **Y Combinator — Work at a Startup:** Canal directo sin intermediarios para superar los $8,000 USD/mes. Empresas activas incluyen Runtime (YC) (buscando *Forward Deployed AI Engineer* en rango $100k–$200k USD/año, cofundada por el ex-fundador de Mentum YC S21 con fuerte presencia en LatAm), Retell AI (YC) (buscando *Senior FDE* bilingüe para despliegues de agentes de voz en Latinoamérica), Output Labs (YC) (*Software Engineer, Agents* enfocado en MCP e inferencia), Weave (YC W25) y Gumloop (YC W24).
- **Wellfound (filtros South America / Chile):** Reúne contrataciones directas como Qase (Senior Engineer, MCP & Developer Tools), Contractor Gorilla (Founding Engineer / Tech Lead AI Platform), Brex, AssemblyAI, Fireflies.ai, Infisical, Topsort y AE Studio.
- **Turing, Revelo, BairesDev y Silver.dev:** Turing y Revelo contratan ingenieros en Chile y LatAm para crear entornos contenerizados de Reinforcement Learning (RL) y suites de evaluación para laboratorios fundacionales de EE. UU. BairesDev mantiene posiciones abiertas de Agentic AI

Engineer y AI Orchestration Engineer, mientras que Silver.dev coloca perfiles Senior en startups de EE. UU. sobre los $110,000 USD/año.

- **Scaleups en Chile y LatAm con Foco en Agentes e Infraestructura:** Vambe AI (contratando *Platform & Infrastructure Engineers* en Chile para su motor de agentes conversacionales), Toku (tras su Serie A de $48M USD y el lanzamiento de sus Agentes de IA de Cobranza, busca *Forward Deployed Engineers* y *Senior Software Engineers*), Fintual, Xepelin, Buk (Buk AI / Buk Studio) y Kueski (Staff AI Software Engineer Remote).

---

2. Requisitos Técnicos Indispensables y Pruebas Técnicas en 2026

Las entrevistas técnicas actuales descartan candidatos cuyo conocimiento se limita a invocar `ChatCompletion` dentro de un endpoint síncrono. Los evaluadores ponen a prueba la capacidad de construir sistemas asíncronos no bloqueantes, persistencia transaccional y analítica híbrida, servidores MCP resistentes a inyecciones y sandboxes aislados a nivel de kernel o virtualización.

A. Stack de Backend, Concurrencia Asíncrona y Ejecución Duradera

- **Python Asíncrono de Alto Rendimiento:** Uso obligatorio de uv para gestión determinista de paquetes en contenedores, FastAPI y Pydantic v2 (núcleo en Rust). En pruebas de código en vivo se penaliza cualquier llamada bloqueante de I/O o CPU dentro del event loop de `asyncio`; se evalúa la orquestación concurrente con `asyncio.TaskGroup`, control de *rate-limits* mediante `asyncio.Semaphore`, cancelación limpia de tareas huérfanas y delegación de análisis AST o parsing pesado a un `ProcessPoolExecutor`.
- **Orquestación de Estado (FSM vs. Grafos Cíclicos):** Dominio de PydanticAI para inyección de dependencias tipada y validación estricta de herramientas, junto con LangGraph o máquinas de estado finitas (FSM) propias que implementen serialización de *checkpoints* por transición, idempotencia ante reintentos y pausas para aprobación humana (*human-in-the-loop*).
- **Streaming Bidireccional y Workflows Duraderos:** Elección justificada entre **SSE** (FastAPI Stream Data con reconexión por `Last-Event-ID` y manejo de *backpressure*), **WebSockets** (FastAPI WebSockets escalados horizontalmente vía Redis Streams) y **WebRTC** (LiveKit Agents para voz con interrupción *barge-in* sub-segundo). Para agentes de larga duración, las empresas exigen motores de *Durable Execution* como Temporal o Inngest que reconstruyen el estado exacto si el worker muere a mitad de un flujo.

B. Persistencia: Postgres Híbrido, DuckDB OLAP y Motores Vectoriales

Capa de Persistencia	Tecnologías Estándar (2026)	Qué Exigen en la Prueba Técnica / System Design
Estado Transaccional + Búsqueda Híbrida Unificada	PostgreSQL + pgvector (HNSW / HalfVec) + pg_search (ParadeDB BM25)	Escribir una consulta SQL con **Reciprocal Rank Fusion (RRF)** combinando similitud vectorial y ranking léxico BM25 (Hybrid Search en Postgres), más particionado declarativo por `tenant_id` o fecha para evitar *index bloat* en tablas de checkpoints (límites de pgvector).

Capa de Persistencia	Tecnologías Estándar (2026)	Qué Exigen en la Prueba Técnica / System Design
Analítica OLAP Embebida y Telemetría de Evals	DuckDB / MotherDuck + Apache Arrow / Parquet en S3	Ingesta columnar sin bloqueos para consultar millones de spans de ejecución, calcular percentiles de latencia (P95/P99) por nodo de la FSM, auditar costos de tokens y ejecutar datasets de evaluación offline directamente sobre archivos Parquet.
Motores Vectoriales a Gran Escala	Qdrant (Rust), Turbopuffer (S3+NVMe), Milvus, Weaviate	Justificar *trade-offs*: Qdrant para filtrado estricto de metadatos en un paso con cuantización binaria vs. Turbopuffer para indexar miles de millones de vectores de código sobre almacenamiento de objetos a bajo costo.

C. Cómo Evalúan MCP, Sandboxing y Evals Automatizados en Entrevistas

- **Model Context Protocol (MCP) y Seguridad de Herramientas:** Los entrevistadores evalúan la arquitectura Host–Client–Server y la migración del antiguo transporte HTTP+SSE al estándar Streamable HTTP (con cabeceras explícitas en la Release Candidate 2026-07-28). Se exige implementar *Tool Discovery* dinámico (para no saturar la ventana de contexto con cientos de esquemas JSON) y defensas frente a ataques de Tool Poisoning documentados por Invariant Labs y Rug Pulls en MCP: fijado criptográfico (hash pinning) de descripciones de herramientas, aislamiento de salidas no confiables y validación de políticas fuera del bucle del LLM (OPA/Cedar).
- **Sandboxing de Ejecución (AST + gVisor + Firecracker):** Ejecutar código generado por un LLM en un contenedor Docker estándar (`runc`) se reprueba en entrevistas de arquitectura por el riesgo de escape hacia el kernel compartido del host. La respuesta ganadora plantea una **defensa en profundidad**:
  1. **Pre-vuelo determinista (AST Validation):** Parseo del árbol sintáctico abstracto en menos de 5 ms para bloquear imports prohibidos (`os`, `subprocess`, `socket`), reflexión maliciosa o bucles sin cota antes de despachar el trabajo.
  2. **Aislamiento de Syscalls o Hardware:** Uso de gVisor (`runsc`) para interceptar syscalls en un kernel en espacio de usuario escrito en Go (comparativa Firecracker vs gVisor), o microVMs Firecracker con KVM (arranque en ~125 ms y <5 MB de RAM overhead), tal como operan E2B, Modal Sandboxes, Fly Machines y Daytona.
- **Evals Continuos en CI/CD (Pass@k vs. Pass^k):** Basado en el benchmark τ-bench de Sierra Research, las entrevistas distinguen entre **Pass@k = 1 − (1 − p)^k** (probabilidad de que *al menos uno* de *k* intentos acierte, útil en generación de código offline) y **Pass^k = p^k** (probabilidad de que *los k intentos consecutivos* sean exitosos y consistentes en producción). Un agente con Pass@1 = 80% cae a Pass^8 = 0.80^8 ≈ 16.7% de fiabilidad en producción (guía de τ-bench). Se evalúa la integración en GitHub Actions de herramientas como Braintrust, DeepEval, Ragas, Arize Phoenix (OpenTelemetry), LangSmith y Promptfoo (Red-Teaming MCP).

3. Estrategia de Conversión con tu Portafolio ("Autonomous Agent Runtime")

Tu repositorio (**Autonomous Agent Runtime con FSM, sandboxing AST, persistencia OLAP en DuckDB y CI/CD con Evals continuos**) ataca exactamente los cuatro dolores de producción de 2026: determinismo de estado, seguridad de ejecución, observabilidad analítica sin infraestructura pesada y prevención de regresiones. A continuación se detalla el **Top 5 de categorías de empresas** donde este proyecto logra la tasa más alta de conversión a entrevista directa:

Categoría de Empresa	Dolor Técnico que Resuelve tu Repo	Ángulo a Destacar en la Postulación	Empresas Objetivo Verificadas
1. Plataformas de Sandboxing, Runtimes y Durable Execution	Aislar código generado por agentes y persistir transiciones de estado ante caídas de red o timeouts.	Serialización determinista de tu **FSM** e inspección pre-ejecución en el **Sandbox AST** + contenedores.	E2B, Daytona, Modal Labs, Inngest, Trigger.dev, Temporal
2. DevTools de Observabilidad, Tracing y Evaluación (LLMOps)	Ingerir millones de spans de agentes, consultarlos en milisegundos y bloquear PRs con regresiones.	Esquema columnar en **DuckDB OLAP** para telemetría de trazas y **Eval Gates en CI/CD**.	Braintrust, LangChain / LangGraph, Arize AI, Langfuse, MotherDuck
3. Startups YC (Seed / Series A) de Agentes Verticales	Reemplazar prototipos frágiles por un motor propio, auditable y rápido sin depender de abstracciones opacas.	Propiedad **End-to-End del Runtime** desde cero; capacidad de actuar como *Founding AI Systems Engineer*.	Browserbase, Greptile, Weave (YC W25), Gumloop, Runtime (YC)
4. FinTechs y B2B SaaS (EE. UU. y Chile/LatAm)	Ejecutar agentes sobre pagos, cobranza o riesgo crediticio con cero tolerancia a acciones no autorizadas.	**Guardrails AST + FSM** (prevención de llamadas ilegales) y trazabilidad auditable en DuckDB.	**US:** Ramp, Brex **LatAm:** Toku, Fintual, Xepelin, Kueski
5. Forward Deployed AI & Enterprise Agents	Demostrar fiabilidad estadística (Pass^k) ante clientes corporativos regulados y depurar fallos en producción.	Suite reproducible de **CI/CD Evals** y consultas analíticas instantáneas de fallos en **DuckDB**.	Sierra, Decagon, Harvey, Anthropic (Applied AI), Artefact US

Playbook de Cold Outreach para Tech Leads, CTOs y Founders

Los CTOs y Staff Engineers revisan correos y DMs desde el teléfono entre reuniones; ignoran textos genéricos de postulación, pero abren de inmediato notas técnicas concisas entre pares que incluyen arquitectura verificable y un demo directo al grano.

Plantilla 1: Cold Email para CTO / VP of Engineering (menos de 95 palabras)

Asunto: FSM agent runtime + AST sandbox & DuckDB evals (demo de 90s para el equipo de plataforma)

Hola [Nombre],

Vi que en [Empresa] están escalando la capa de ejecución de agentes en producción y pensé que te interesaría ver un runtime autónomo que construí desde cero para resolver el determinismo de estado y el aislamiento de ejecución sin depender de frameworks pesados:
• **Orquestación determinista y segura:** Máquina de estados finitos (FSM) asíncrona con reintentos idempotentes y un sandbox AST que bloquea código no autorizado en <5 ms antes de tocar el entorno.
• **Telemetría OLAP embebida:** Persistencia en DuckDB para consultar trazas, latencia P95 por nodo y costo de tokens en milisegundos.
• **Confiabilidad en CI/CD:** Suite automatizada de Evals ($Pass^k$ y validación de herramientas) que bloquea el merge ante regresiones.

Grabé un recorrido técnico de 90 segundos directo al código y terminal: [Enlace Loom] (repo y benchmarks aquí: [Enlace GitHub]).

Estoy disponible para contratos B2B remotos desde Chile (huso horario compatible con ET) en roles de AI Systems / Platform Engineering. ¿Tienes 15 minutos este jueves para conversar?

Plantilla 2: DM Directo en LinkedIn o X para Founding Engineers / Tech Leads

Hola [Nombre] — vi que están escalando la infraestructura de agentes en [Empresa]. Construí un runtime autónomo propio muy alineado con los retos de producción que tienen hoy: **FSM explícita** para control de estado, **sandboxing AST** para ejecución segura de herramientas, telemetría columnar en **DuckDB** y **gates de Evals ($Pass^k$) en CI/CD**.

Dejé un demo técnico de 90s sin relleno aquí ([Enlace Loom]) y el repo público ([Enlace GitHub]). Si están sumando AI Systems Engineers al equipo este trimestre, encantado de conversar.

Estructura Exacta del Video Demo de 90 Segundos (Regla de los Primeros 15 Segundos)

- **Segundos 00–15 (El Gancho en Terminal):** Cero diapositivas ni presentaciones biográficas. Abre con pantalla dividida entre tu grafo de estados FSM en código y una terminal en vivo donde el agente intenta ejecutar una instrucción maliciosa o fuera de política, mostrando cómo el validador AST la intercepta en menos de 5 ms y registra el evento.
- **Segundos 15–55 (Recuperación de Fallos + Telemetría DuckDB):** Simula un corte o timeout en una herramienta MCP externa, demuestra cómo la FSM reanuda exactamente desde el último checkpoint persistido sin duplicar efectos secundarios y ejecuta en vivo una consulta SQL analítica sobre DuckDB mostrando latencias por estado y consumo de tokens.
- **Segundos 55–90 (El Gate de CI/CD en GitHub Actions):** Muestra un Pull Request real en tu repositorio donde un cambio degrada la consistencia ($Pass^k$) del agente y el workflow de CI/CD bloquea automáticamente el merge con el reporte de regresión detallado.